Africa TechUp Tour 2025-2026

Projet Fil Conducteur

# Prédiction de la qualité de l'air à Beijing : Modélisation des concentrations de PM2.5

Réalisé par : **Abdoul Fataho NIAMPA**

# Table des matières

1. Introduction ..... 2
2. Objectif du projet ..... 2
2.1. Contexte et problématique ..... 2
2.2. Objectifs opérationnels ..... 2
2.3. Impact attendu ..... 3
3. Méthode ..... 3
3.1. Données ..... 3
3.2. Feature Engineering ..... 3
3.3. Partitionnement des données ..... 4
3.4. Modèles comparés ..... 5
4. Résultats ..... 5
4.1. Comparaison des modèles ..... 5
4.2. Prédictions vs Réalité : Suivi des tendances ..... 6
4.3. Performances du modèle final : LightGBM ..... 6
4.4. Importance des variables et analyse SHAP ..... 6
4.5. Lecture des graphiques SHAP : Interactions et non linéarités ..... 9
4.6. Exemples SHAP : Analyse individuelle des prédictions ..... 9
4.7. Synthèse opérationnelle pour les décideurs ..... 10
5. Limites et perspectives ..... 10
6. Conclusion ..... 12

# 1. Introduction

La pollution atmosphérique constitue aujourd'hui un enjeu sanitaire majeur pour les grandes métropoles. À Beijing, les particules fines PM2.5, dont le diamètre inférieur à 2,5 µm leur permet de pénétrer profondément dans le système respiratoire et sanguin, sont particulièrement dangereuses. Elles sont associées à une hausse des maladies cardiorespiratoires et à une diminution de l'espérance de vie.

Dans un contexte de Smart City, l'exploitation de données et l'intelligence artificielle offrent de nouvelles possibilités pour anticiper les épisodes de pollution et mettre en place des mesures proactives. Cette démarche repose notamment sur la capacité à prévoir les niveaux de PM2.5 à court terme afin de soutenir la prise de décision urbaine.

# 2. Objectif du projet

## 2.1. Contexte et problématique

Les grandes villes comme Beijing font face à une intensification des épisodes de pollution atmosphérique liée aux particules fines PM2.5. Leur petite taille leur permet d'atteindre les zones profondes des poumons et de circuler dans le système sanguin, entraînant des risques sanitaires élevés.

Dans cette dynamique, les approches de Smart City offrent des outils capables de transformer des données météorologiques et historiques en prédictions utiles pour la gestion environnementale.
La problématique centrale du projet est la suivante :

*Comment prédire le niveau de pollution PM2.5 du lendemain (J+1) à partir des données météorologiques et historiques, afin de permettre à la ville d'anticiper des mesures de gestion adaptées ?*

## 2.2. Objectifs opérationnels

Le projet poursuit cinq objectifs complémentaires :

| Objectif | Description |
|---|---|
| **Prédiction** | Estimer le niveau moyen de PM2.5 du lendemain (J+1) pour l'ensemble de la ville. |
| **Interprétabilité** | Identifier les variables météorologiques et temporelles les plus déterminantes. |
| **Visualisation** | Proposer des graphiques synthétiques et pertinents pour les décideurs urbains. |
| **Application** | Déployer une application Streamlit permettant de simuler différents scénarios. |
| **Aide à la décision** | Fournir des éléments actionnables permettant d'agir 24 h à l'avance. |

### 2.3. Impact attendu

Une prévision fiable à horizon 24 h offrirait aux autorités la possibilité de :

- Déclencher des alertes pollution avant l'atteinte du seuil critique de 150 µg/m³
- Réguler la circulation (restrictions, zones à faibles émissions)
- Ajuster l'offre de transport public selon le niveau de risque
- Protéger les populations sensibles via des mesures préventives

Cette capacité d'anticipation constitue un levier essentiel pour renforcer la gestion environnementale et améliorer la qualité de vie urbaine.

## 3. Méthode

### 3.1. Données

Le projet repose sur le jeu de données UCI Beijing PM2.5, couvrant la période du 1er janvier 2010 au 31 décembre 2014, avec une granularité horaire, soit 43 824 observations. Les informations disponibles incluent des mesures de pollution, des variables météorologiques et des indicateurs temporels.

| Variables | Type | Description |
|---|---|---|
| **pm2.5 (cible)** | Numérique | Concentration de PM2.5 en µg/m³ |
| **TEMP** | Météo | Température de l'air (°C) |
| **PRES** | Météo | Pression atmosphérique (hPa) |
| **DEWP** | Météo | Point de rosée (°C) |
| **Iws** | Météo | Vitesse cumulée du vent (m/s) |
| **cbwd** | Météo | Direction dominante du vent (NE, NW, SE, CV) |
| **Is / Ir** | Météo | Heures cumulées de neige / pluie |
| **year / month / day / hour** | Temporelle | Horodatage de la mesure |

Au total, 2 067 valeurs manquantes (4,72 % des observations) concernent la variable *pm2.5*. Elles ont été corrigées par interpolation temporelle, une méthode adaptée aux séries chronologiques pour préserver la continuité du signal.

### 3.2. Feature Engineering

Le **feature engineering** constitue une étape déterminante du projet. La série horaire a d'abord été agrégée à la granularité journalière, puis enrichie à l'aide de plusieurs familles de variables.

**Variables temporelles**

- Jour, mois, heure, jour de la semaine, indicateur week-end
- Encodage de la saison (Hiver, Printemps, Été, Automne)

**Variables météorologiques dérivées**

- Température ressentie (formule de Steadman)
- Delta thermique sur 6 h, indicateur d'inversion thermique imminente
- Catégories de vent (calme / modéré / fort)
- Interactions : température × vent, pression × point de rosée

**Lags et moyennes glissantes horaires**

- pm25_lag_1h, 6h, 12h, 24h : mémoire immédiate
- pm25_roll_3h, 12h, 24h : tendances lissées court / moyen / long terme

**Lags et moyennes glissantes journalières**

| Feature | Justification |
|---|---|
| **pm25_lag_1d … pm25_lag_7d** | Mémoire directe des jours J–1 à J–7 |
| **pm25_roll_3d, 7d, 14d** | Tendances lissées journalières |
| **pm25_delta_1d** | Variation J vs J–1 (accélération / décélération) |

La variable cible correspond à la moyenne journalière du PM2.5 à J+1, préalablement winsorisée au 99e percentile afin de limiter l'influence des pics extrêmes.

Le dataset final comprend 32 variables explicatives pour 43 776 observations exploitables.

### 3.3. Partitionnement des données

Le découpage temporel suit strictement l'ordre chronologique afin d'éviter tout **data leakage**.

| Ensemble | Période | Taille | Rôle |
|---|---|---|---|
| **Train** | 2010–2013 | ~1 461 jours | Entraînement et optimisation |
| **Test** | 2014 | ~365 jours | Évaluation finale (données non vues) |

L'optimisation des modèles repose sur une validation croisée dédiée aux séries temporelles : **TimeSeriesSplit (5 plis)**, garantissant que chaque pli de validation est toujours situé après ses plis d'entraînement.

### 3.4. Modèles comparés

Quatre modèles ont été entraînés, représentant différents niveaux de complexité.

| Modèle | Principe et rôle |
|---|---|
| **Régression Linéaire** | Baseline simple, sensible à la multicolinéarité. Sert de référence minimale. |
| **Random Forest** | Ensemble d'arbres robuste aux non-linéarités et aux outliers. Ne nécessite pas de normalisation. |
| **XGBoost** | Boosting avec régularisation L1/L2, performant sur données tabulaires et interactions complexes. |
| **LightGBM (retenu)** | Gradient boosting à croissance feuille-par-feuille, rapide et très performant. Modèle final déployé. |

Les hyperparamètres de Random Forest, XGBoost et LightGBM ont été optimisés via **RandomizedSearchCV** (15 à 30 itérations), combiné à la validation croisée chronologique.

## 4. Résultats

### 4.1. Comparaison des modèles

Les performances de quatre modèles ont été évaluées sur l'année 2014 (données totalement hors échantillon) :

| Modèle | RMSE (µg/m³) | MAE (µg/m³) | $R^2$ | Rang |
|---|---|---|---|---|
| **Régression Linéaire** | ~57,0 | ~41,0 | 0,568 | 4e |
| **Random Forest** | ~56,5 | ~40,5 | 0,570 | 3e |
| **XGBoost** | ~57,2 | ~41,2 | 0,565 | 4e |
| **LightGBM (retenu)** | **51,76** | **37,16** | **0,574** | **1er** |

**Conclusion** : LightGBM présente le meilleur compromis entre précision, robustesse et stabilité.

## 4.2. Prédictions vs Réalité : Suivi des tendances

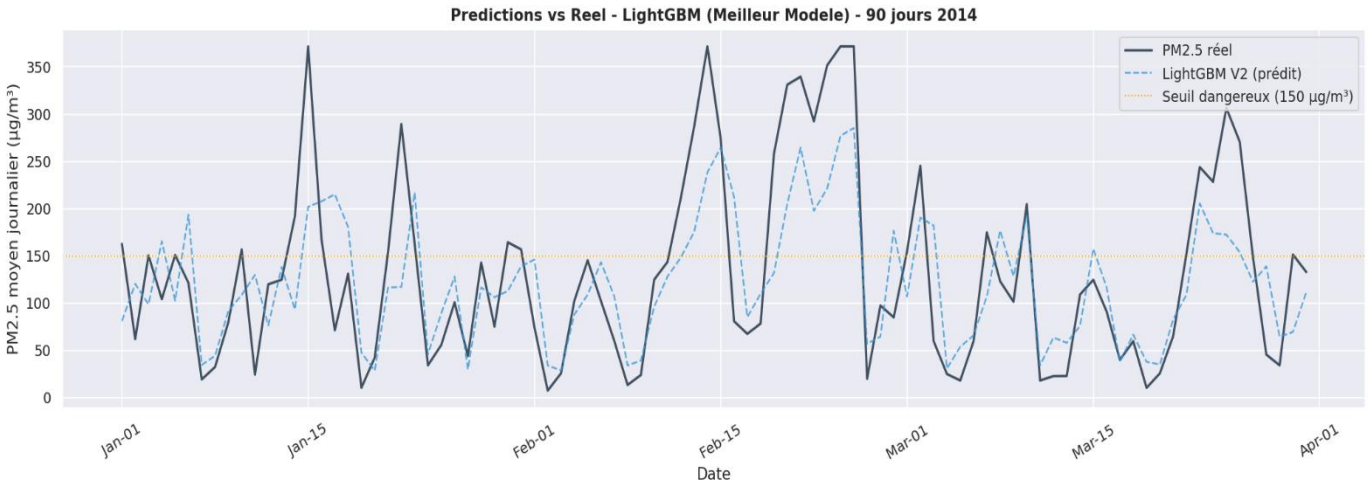


Cette première visualisation confirme la capacité du modèle à reproduire la dynamique générale de la pollution atmosphérique à Beijing.

## 4.3. Performances du modèle final : LightGBM

| Métrique | Valeur | Interprétation |
|---|---|---|
| **RMSE** | 51,76 µg/m³ | Écart-type des erreurs. Les prévisions s'écartent en moyenne de 51,76 unités. |
| **MAE** | 37,16 µg/m³ | Erreur absolue moyenne. Bon niveau de précision malgré la forte volatilité. |
| **$R^2$** | 0,574 | Le modèle explique 57,4 % de la variabilité du PM2.5 à J+1. |
| **nRMSE** | 52,94 % | L'erreur représente environ la moitié de la concentration moyenne observée. |

Le modèle capture de manière fiable les cycles saisonniers, les tendances journalières et une large partie des épisodes de pollution, hormis les pics extrêmes, structurellement plus imprévisibles.

## 4.4. Importance des variables et analyse SHAP

L'analyse SHAP (SHapley Additive exPlanations) fournit une lecture fine de la contribution de chaque variable aux prédictions du modèle. Elle éclaire non seulement l'importance relative des variables, mais aussi les mécanismes physiques sous-jacents à la dynamique du PM2.5. Les valeurs SHAP permettent d'isoler l'effet propre d'un facteur, tout en tenant compte de ses interactions avec les autres variables atmosphériques.

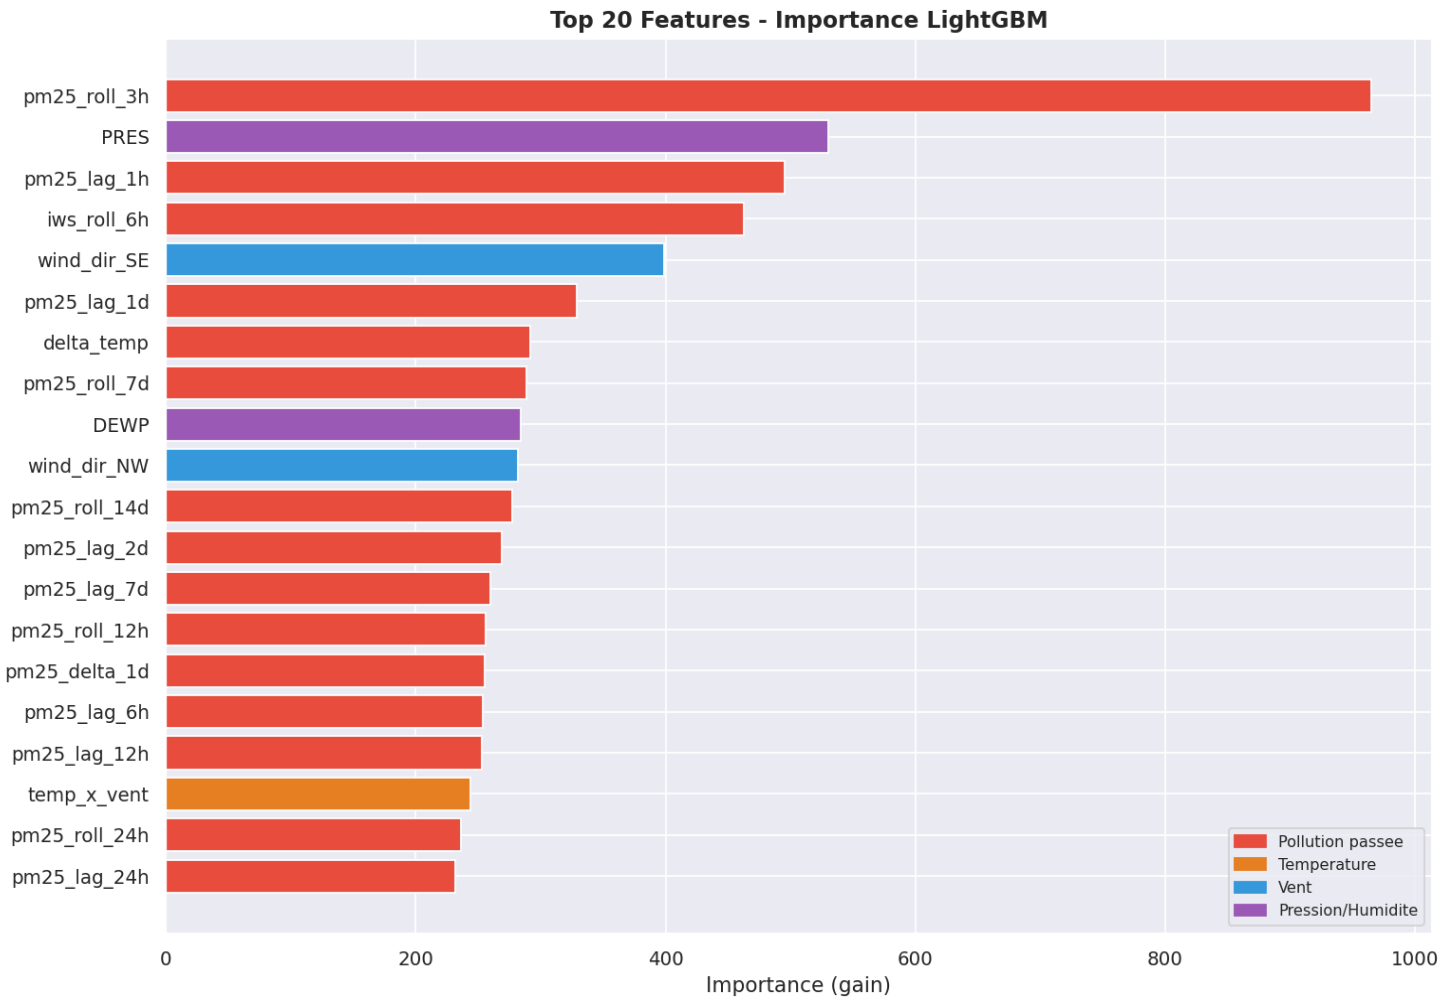


### Enseignement général

Les résultats montrent que la pollution atmosphérique à Beijing est principalement gouvernée par trois ensembles de mécanismes. Ces trois familles structurent l'ensemble de la variabilité du PM2.5 prédit par le modèle.

#### ➢ Famille 1 : Inertie temporelle (facteur dominant)

Les variables liées à la pollution passée apparaissent comme les plus influentes. Elles capturent le phénomène physique d'**accumulation progressive** des particules dans l'air.

**Variables principales :**

- **pm25_roll_3h**
- **pm25_lag_1h**
- **pm25_roll_12h**

Ces indicateurs résument la mémoire du système atmosphérique. La présence de particules fines suit un comportement inertiel :

- lorsque les niveaux de pollution sont élevés,
- et que les conditions météorologiques n'apportent pas de renouvellement d'air,

- la pollution persiste voire augmente.

Le modèle détecte donc que la valeur future du PM2.5 dépend étroitement des heures précédentes, ce qui en fait l'axe principal de prédiction.

### ➢ Famille 2 : Stabilité atmosphérique

La capacité de l'atmosphère à se mélanger verticalement joue un rôle déterminant dans la dispersion ou l'accumulation des particules. Une atmosphère stable favorise la concentration des polluants.

**Variables clés :**

- Pression atmosphérique (PRES) : effet moyen de +5,25 µg/m³
- Point de rosée (DEWP)

Ainsi :

- Une forte pression atmosphérique agit comme un couvercle, limitant les mouvements verticaux et piégeant les particules à proximité du sol.
- Un point de rosée élevé traduit un air humide et dense, renforçant les situations de stagnation.

Ces deux variables interagissent : dans les périodes anticycloniques froides et humides, l'atmosphère se comporte comme une cloche hermétique favorisant les smogs durables.

### ➢ Famille 3 : Vent (direction et vitesse)

Le vent constitue le principal mécanisme naturel de **nettoyage** de l'air. L'analyse SHAP confirme que son rôle est majeur, mais ses effets sont asymétriques selon la direction.

**Variables importantes :**

- wind_dir_NW (Nord-Ouest) : effet négatif marqué → baisse du PM2.5
- wind_dir_SE (Sud-Est) : effet positif → augmentation du PM2.5
- Iws (vitesse du vent) : rôle dispersif

Ainsi :

- Le vent du Nord-Ouest provient des zones montagneuses beaucoup moins industrialisées : il apporte de l'air plus propre.
- Le vent du Sud-Est, au contraire, transporte des masses d'air chargées provenant de zones industrielles et urbaines denses, notamment la province du Hebei : il contribue à augmenter la pollution.
- Une vitesse de vent élevée accélère mécaniquement la dispersion des particules, réduisant significativement les concentrations même si l'inertie de pollution est forte.

### 4.5. Lecture des graphiques SHAP : Interactions et non linéarités

Les graphiques SHAP mettent en évidence plusieurs comportements non linéaires et des interactions structurelles entre variables.

- **pm25_roll_3h**

Le modèle apprend une relation non linéaire :

- lorsque la pollution récente augmente, l'impact sur la prédiction est très fort,
- puis se stabilise au-delà d'un certain seuil (effet de saturation).

- **PRES**

Une rupture nette apparaît autour de **1020 hPa** :

- sous ce seuil, l'effet de la pression reste modéré,
- au-dessus, l'atmosphère devient quasi hermétique, ce qui fait s'envoler les contributions SHAP positivement.

- **Vent**

Les effets du vent sont modulés par :

- la saison (vents d'hiver plus forts et plus froids),
- l'humidité,
- la pollution déjà présente.

Un vent faible dans un contexte de forte inertie ou de forte humidité devient insuffisant pour disperser les particules.

### 4.6. Exemples SHAP : Analyse individuelle des prédictions

Les explications individuelles illustrent concrètement comment les facteurs atmosphériques conduisent à des niveaux très différents de pollution.

- **Pic de pollution : 25 février 2014 (285,3 µg/m³)**

**Facteurs dominants :**

- inertie élevée (pm25_roll_3h très haut)
- pression atmosphérique forte → atmosphère bloquée
- absence de vent nettoyant

La pollution s'est accumulée pendant plusieurs heures, sans vent du Nord-Ouest pour la disperser. Les conditions anticycloniques ont piégé les particules, conduisant à un smog marqué.

- **Jour médian : 9 janvier 2014 (91,7 µg/m³)**

**Mécanisme :**

- augmentation liée au froid hivernal et au chauffage
- effet partiellement compensé par un vent léger

L'équilibre entre sources de pollution (chauffage) et dispersion (vent modéré) explique un niveau intermédiaire, très représentatif de l'hiver à Beijing.

- **Air propre : 2 septembre 2014 (26,9 µg/m³)**

**Facteur décisif :** vent fort du Nord-Ouest

Les masses d'air propres venant du Nord-Ouest ont rapidement dispersé les particules, produisant l'un des niveaux les plus bas de l'année.

### 4.7. Synthèse opérationnelle pour les décideurs

Trois conclusions clés peuvent guider la gestion opérationnelle de la qualité de l'air.

- **La pollution d'hier est la meilleure prédiction de demain**

Les phases d'accumulation doivent être identifiées rapidement, car elles entraînent des épisodes prolongés de pollution.

*Implication : surveillance continue des tendances horaires.*

- **Les épisodes de haute pression doivent déclencher des alertes**

Les situations anticycloniques sont fortement associées aux pics de PM2.5.

*Implication : mise en place d'un système d'alerte météorologique-pollution.*

- **Le vent est le meilleur allié pour faire baisser le PM2.5**

Lorsque les prévisions annoncent des vents modérés à forts du Nord-Ouest, les risques de pollution diminuent fortement.

*Implication : intégrer les prévisions de vent aux outils de décision pour anticiper les épisodes de smog.*

## 5. Limites et perspectives

L'évaluation du modèle met en évidence plusieurs limites qui relèvent à la fois des données utilisées et de la nature des algorithmes mobilisés. Tout d'abord, les données disponibles sont spécifiques à la ville de Beijing, ce qui limite la transférabilité du modèle à d'autres contextes géographiques où les mécanismes de pollution, la dynamique atmosphérique et les sources d'émissions peuvent différer fortement. De plus, le dataset ne contient aucune information

directe sur les sources d'émissions telles que le trafic routier, l'activité industrielle, les chantiers urbains ou les brûlis agricoles. Ces facteurs représentent pourtant une part substantielle de la variabilité réelle du PM2.5, et leur absence contraint le modèle à s'appuyer principalement sur des variables météorologiques et des effets d'inertie, au détriment d'une représentation plus complète des déterminants de la pollution.

Une autre limite tient à l'agrégation des données à l'échelle journalière. Cette simplification facilite le traitement et l'entraînement du modèle, mais elle entraîne une perte notable d'information, notamment l'effacement des pics horaires, des phénomènes d'inversion thermique rapide ou encore des phases de dispersion soudaines induites par des changements de vent. Sur le plan méthodologique, les modèles entraînés restent des outils statistiques fondés sur la corrélation : ils capturent des relations empiriques mais ne modélisent pas les processus physiques sous-jacents de transport, de réaction chimique ou de dispersion des particules. Cette dépendance aux corrélations rend le système moins robuste lorsque les conditions s'écartent des situations déjà observées dans les données historiques.

Le modèle rencontre également des difficultés à prédire avec précision les extrêmes, notamment les épisodes de pollution très élevée au-delà de 300 µg/m³. Ces événements rares sont peu représentés dans les données d'apprentissage, ce qui conduit le modèle à atténuer systématiquement les valeurs maximales. Enfin, l'horizon de prédiction utilisé, limité à J+1, constitue une autre faiblesse : toute tentative d'étendre la prévision à plusieurs jours entraînerait une accumulation rapide des incertitudes et une dégradation notable des performances.

Au regard de ces limites, plusieurs pistes d'amélioration apparaissent pertinentes. Un premier axe consiste à enrichir les données en intégrant des sources externes. Les données satellitaires, telles que MODIS ou Sentinel, pourraient fournir des informations précieuses sur l'épaisseur optique des aérosols ou la couverture nuageuse à l'échelle régionale. L'ajout de données sur le trafic routier, l'activité industrielle ou les feux de biomasse permettrait de capturer plus directement les variations liées aux émissions. L'intégration d'informations topographiques, notamment sur la morphologie urbaine, améliorerait la modélisation des zones de stagnation et des couloirs de ventilation.

Sur le plan méthodologique, l'utilisation de modèles avancés constitue une perspective intéressante. Les architectures de deep learning, telles que les LSTM ou les Transformers temporels, offrent la capacité de capter des dépendances longues et des interactions complexes difficiles à modéliser avec des approches classiques. Des modèles hybrides combinant, d'une part, un modèle physique atmosphérique et, d'autre part, un modèle statistique destiné à corriger les biais, pourraient renforcer la robustesse et l'extrapolation du système. Par ailleurs, l'introduction de prédictions probabilistes, plutôt que de valeurs ponctuelles uniques, offrirait aux décideurs des intervalles de confiance indispensables pour la gestion du risque sanitaire.

Enfin, concernant la mise en production, l'application Streamlit développée dans le cadre du projet constitue une première étape fonctionnelle, puisqu'elle permet de simuler des scénarios météorologiques et d'obtenir des prévisions en temps réel. La prochaine étape logique consiste à connecter le modèle à une API fournissant des données météorologiques en continu, afin d'automatiser les prévisions et de diffuser des alertes aux gestionnaires et institutions concernées. Un système de réentraînement périodique pourrait également être mis en place afin de maintenir la performance du modèle au fil du temps.

## 6. Conclusion

En somme, ce projet montre qu'il est possible de construire un système de prévision du PM2.5 à 24 heures basé sur des techniques de machine learning, avec des performances solides au regard de la complexité des phénomènes atmosphériques. Le modèle LightGBM obtient un $R^2$ de 0,574 et un RMSE de 51,76 µg/m³, confirmant son aptitude à fournir des prédictions opérationnelles. L'analyse SHAP renforce la crédibilité scientifique des résultats, en montrant que les mécanismes identifiés, inertie temporelle, pression atmosphérique, humidité et vent sont cohérents avec les connaissances physiques sur la pollution. Le principal enseignement du projet est que la pollution PM2.5 est avant tout un phénomène d'accumulation piloté par des conditions météorologiques, et que cette compréhension peut être directement exploitée pour orienter les politiques de gestion proactive de la qualité de l'air dans une perspective de ville intelligente.

Lien vers l'application : https://afn-projet-pm25-cybkwjc2tszedlupcrxpog.streamlit.app